

SVM推导(Hard Margin)

要点: KKT是为了推强对偶, 之后是无约束问题, 不再用KKT条件求解, 而是直接求导求解

数据:  $(X, Y), X \in R^n, Y \in \{-1, 1\}$

分类超平面:  $Y = WX + b$

决策函数:  $f(x_i) = \text{sign}(Wx_i + b)$

当所有的点被正确分类时:  $y_i * (Wx_i + b) > 0$

上式可以缩放为:  $y_i * (Wx_i + b) \geq 1, \min(y_i * (Wx_i + b)) = 1$

根据点到直线的距离公式, 定义:  $\text{margin}(W, b, X) = \frac{1}{\|W\|} |WX + b|$

优化目标:  $= \arg \max_{W, b} \left\{ \frac{1}{\|W\|} \min(y_i * (Wx_i + b)) \right\} = \arg \max_{W, b} \left\{ \frac{1}{\|W\|} \right\}$

转化成极小值问题: 公式

$$\begin{cases} \min_{W, b} \frac{1}{2} W^2 \\ s. t. y_i (WX_i + b) \geq 1 \end{cases}$$

拉格朗日函数:  $L(W, b, \lambda) = \frac{1}{2} W^2 + \sum_{i=1}^N \lambda_i (1 - y_i (Wx_i + b))$

原问题等价于

$$\begin{cases} \min_{W, b} \max_{\lambda} L(W, b, \lambda) \\ s. t. \lambda_i \geq 0 \end{cases}$$

KKT条件 (最优解的必要条件) :

约束问题:  $\min f(x)$

$s. t. g_j(x) = 0, j = 1, \dots, m \quad h_k(x) \leq 0, k = 0, 1, \dots, p$

拉格朗日函数:  $L(x, \{\lambda_j\}, \{\mu_k\}) = f(x) + \sum_{j=1}^m \lambda_j g_j(x) + \sum_{k=1}^p \mu_k h_k(x)$

KKT条件包括:

$$\begin{cases} \nabla_x L = 0 \\ g_j(x) = 0, & j = 1, 2, \dots, m. \\ h_k(x) \leq 0, & k = 1, 2, \dots, p. \\ \mu_k \geq 0 \\ \mu_k h_k(x) = 0, & k = 1, 2, \dots, p. \end{cases}$$

KKT条件使用时要满足某些要求 (Constraint Qualification, CQ) , 最常用的CQ是strict feasibility和Linearity constraint qualification:

1. 存在一个点, 使得所有的约束条件都严格成立
2. 等式约束和不等式约束都是线性的

弱对偶:  $\max \min f \leq \min \max f$

强对偶:  $\max \min f = \min \max f$

强对偶可以推出KKT条件成立, 对于凸优化问题, CQ可以推出强对偶。

显然满足这两个条件, 所以KKT条件成立, 强对偶定理成立。

用强对偶定理, 问题继而转化成

$$\begin{cases} \max_{\lambda} \min_{W, b} L(W, b, \lambda) \\ s. t. \lambda_i \geq 0 \end{cases}$$

先求解,

$$\begin{cases} \min_{W, b} L(W, b, \lambda) \\ s. t. \lambda_i \geq 0 \end{cases}$$

凸二次优化问题, 直接求解, 令  $\frac{\partial L}{\partial W} = 0, \frac{\partial L}{\partial b} = 0$

得,  $W = \sum_{i=1}^N \lambda_i y_i x_i, \sum_{i=1}^N \lambda_i y_i = 0$

带入L得,  $L = \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j y_i y_j x_i^T x_j$

求解b,b只与落在间隔线上的点有关, 此时, 必有  $y_k(Wx_k + b) = 1, \lambda_k \neq 0,$

所以,  $b = y_k - \sum_{i=1}^N \lambda_i y_i x_i^T x_k$

进而求解

$$\begin{cases} \max_{\lambda} L = \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j y_i y_j x_i^T x_j \\ s. t. \lambda_i \geq 0, \sum_{i=1}^N \lambda_i y_i = 0 \end{cases}$$

用SMO算法求解.